# 1 实验目的与方法

实验目的:实现一个 Java 实现的 TXTv2 语言编译器,目标平台为 RISC-V 32(指令集 RV32M);深入了解编译程序实现原理及方法。

# 1.1 词法分析器

## 实验目的:

- 1. 加深对词法分析程序的功能及实现方法的理解。
- 2. 对类 C 语言单词符号的文法描述有更深的认识,理解有限自动机、编码表和符号表在编译的整个过程中的应用。
- 3. 设计并编程实现一个词法分析程序,对类 C 语言源程序段进行词法分析,加深对高级语言的认识。

实验环境: Java 17; IntelliJ IDEA 2022.2.2

# 1.2 语法分析

# 实验目的:

- 1. 深入了解语法分析程序实现原理及方法。
- 2. 理解 LR(1)分析法是严格的从左向右扫描和自底向上的语法分析方法。

实验环境: Java 17; IntelliJ IDEA 2022.2.2; 编译工作台

# 1.3 典型语句的语义分析及中间代码生成

### 实验目的:

- 1. 加深对自底向上语法制导翻译技术的理解,掌握声明语句、赋值语句和算术运算语句的翻译方法。
- 2. 巩固语义分析的基本功能和原理的认识,理解中间代码的作用。

实验环境: Java 17; IntelliJ IDEA 2022.2.2

# 1.4 目标代码生成

### 实验目的:

- 1. 加深对编译器总体结构的理解与掌握:
- 2. 掌握常见的 RISC-V 指令的使用方法;
- 3. 理解并掌握目标代码生成算法和寄存器选择算法。

实验环境: Java 17; IntelliJ IDEA 2022.2.2

# 2 实验内容及要求

# 2.1 词法分析器

编写一个词法分析程序,读取文件,对文件内的类C语言程序段进行词法分析。

- 1. 输入: 以文件形式存放的类 C 语言程序段;
- 2. 输出: 以文件形式存放的 TOKEN 串和简单符号表。

# 2.2 语法分析

编写一个语法分析程序,读取实验一获取的 token 表,对文件内的类 C 语言程序 段进行语法分析。

- 1. 利用自底向上的 LR(1)分析法,设计语法分析程序,对输入单词符号串进行语法分析;
- 2. 输出推导过程中所用产生式序列并保存在输出文件中;
- 3. 支持变量声明、变量赋值、基本算术运算的文法;
- 4. 要求:实验一的输出作为实验二的输入。

# 2.3 典型语句的语义分析及中间代码生成

完成语义分析及中间代码生成的观察者模式代码,在实验二自底向上语法分析文法的基础上实现一个 S-SDD 的 SDT,为语法正确的单词串设计翻译方案,完成语法制导翻译。

- 1. 利用该翻译方案,对所给程序段进行分析,输出生成的中间代码序列和更新后的符号表,并保存在相应文件中,中间代码使用三地址码的四元式表示。
- 2. 实现声明语句、简单赋值语句、算术表达式的语义分析与中间代码生成。
- 3. 使用框架中的模拟器 IREmulator 验证生成的中间代码的正确性。

# 2.4 目标代码生成

完成目标代码生成程序。

- 1. 将实验三生成的中间代码转换为目标代码(RISC-V 指令):
- 2. 使用 RARS 运行生成的目标代码,验证结果的正确性。

# 3 实验总体流程与函数功能描述

# 3.1 词法分析

## 2.1.1. 编码表

无更多功能,故采用了实验 template 项目中自带的`coding\_map`文件中的编码表,如下所示:

```
1 int
2 return
3 =
4,
5 Semicolon
6+
7 -
8 *
9 /
10 (
11 )
51 id
52 IntConst
```

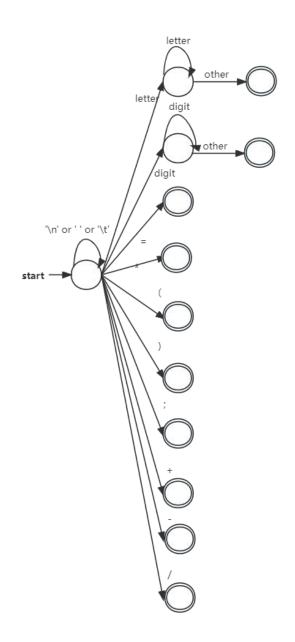
## 2.1.2. 正则文法

```
G=(V,T,P,S),其中 V=\{S,A,B,Cdigit,no_0\_digit,,char\},T=\{任意符号\},约定:用 digit 表示数字: 0,1,2,…,9; no_0_digit 表示数字: 1,2,…,9; 用 letter 表示字母: A,B,…,Z,a,b,…,z,_
```

```
则 P 定义如下:
```

```
标识符: S \rightarrow letter A; A \rightarrow letter A | digit A | \epsilon; 整常数: S \rightarrow no_0 - digitB; B \rightarrow digitB | \epsilon; 运算符: S \rightarrow C; C \rightarrow =|*|+|-|/
```

## 2.1.3. 状态转换图



## 2.1.4. 词法分析程序设计思路和算法描述

设计思路: 根据状态转移图,通过状态机实现词法分析程序。 算法描述:

- 1. 设置初始状态为0;
- 2. 读入文件一个字符,根据字符情况进行状态转移;
- 3. 若转移到终结状态,则向 token 表中新增一条符号记录,然后转移到状态 0;
- 4. 重复过程 2、3, 直到读到文件终止字符。

## 部分代码如下:

```
public void run() {
   for (String line: file_lines) { // 读取文件
       State state = State.ZERO;
       StringBuilder sb = new StringBuilder();
       for (char c : line.toCharArray()) {
           switch (state) { // 状态转移
              case FORTEEN:
                  if ((c >= 'a' \&\& c <= 'z') || (c >= 'A' \&\& c <= 'Z') || (c >= '0' \&\& c
<= '9')) {
                      state = State.FORTEEN;
                      sb.append(c);
                  } else { // 遇到终结符则进行符号表写入,并转移到状态 0
                      state = State.ZERO; // 转移到状态 0
                      if (sb.toString().equals("int")) { // 遇到终结符则进行符号表写入
                         tokens.add(Token.normal(TokenKind.fromString("int"), ""));
                      } else if (sb.toString().equals("return")){
                         tokens.add(Token.normal(TokenKind.fromString("return"), ""));
                      } else {
                         tokens.add(Token.normal(TokenKind.fromString("id"),
sb.toString()));
                         symbolTable.add(sb.toString());
                      }
                      sb = new StringBuilder();
                  }
                  break;
              ... // 省略
          }
       }
   }
   tokens.add(Token.normal(TokenKind.eof(), "")); // 添加符号表结束标志
```

# 3.2 语法分析

## 3.2.1 拓展文法

无更多功能,故采用了实验 template 项目中自带的`grammer.txt`文件中的文法,如下所示:

```
P -> S_list;
S_list -> S Semicolon S_list;
```

```
S_list -> S Semicolon;

S -> D id;

D -> int;

S -> id = E;

S -> return E;

E -> E + A;

E -> E - A;

E -> A;

A -> A * B;

A -> B;

B -> (E);

B -> id;

B -> IntConst;
```

## 3.2.2 LR1 分析表

使用编译工作台按照指导书步骤对`grammer.txt`文件中的文法进行了分析表的构建与导出,最终存放在项目的`data\in\LR1\_table.csv`中。

### 3.2.3 状态栈和符号栈的数据结构和设计思路

- 1. 符号栈
- ① 数据结构: Stack<Term> symbolStack = new Stack<>();
- ② 设计思路:由于为栈结构,并且里面存放的为终结符和非终极符,故采用了 Java 的 Stack 类,并且将泛型设置为终结符和非终极符类的父接口 Term。
- 2. 状态栈
- ① 数据结构: Stack<Status> statusStack = new Stack<>();
- ② 设计思路:由于为栈结构,并且里面存放的为 Status 类,故采用了 Java 的 Stack 类,并且将泛型设置为 Status。
- 3. 词法单元存储
- ① 数据结构: List<Token> buffer = new LinkedList<>();
- ② 设计思路:由于 buffer 可以视为队列结构的条带,在初始化时填充队列,之后也仅需从队头获取元素,并且无需遍历操作,故而采用增删元素较为方便、性能较佳的 LinkedList 来存储数据。

### 3.2.4 LR 驱动程序设计思路和算法描述

设计思路:通过LR分析表和LR文法的分析逻辑进行语法分析。算法描述:

- 1. 每次读取状态栈顶和输入首部字母, 进行查表。
  - 1. 若查出 sx,则弹出首部字母,将其及其状态 x 入栈。

- 2. 若查出 rx, 用第 x 个产生式归约符号栈(出栈符号及其对应状态, 入栈归约结果),查询左部符号对应 GOTO 表,将 GOTO 表对应状态 x入状态栈。
- 2. 重复 1, 直到得到 acc。

部分代码如下:

```
public void run() {
   while(true) {
      Status status = statusStack.peek(); // 状态栈头元素
       Token symbol = buffer.get(0); // 输入队列头元素
      Action action = status.getAction(symbol); // 查询LR分析表
       switch (action.getKind()) { // 根据查询结果进行状态转换
          case Reduce: // rx
              Production production = action.getProduction(); // 获取产生式
              int length = production.body().size(); // 弹出状态栈和符号栈对应元素
              for (int i = 0; i < length; i++) {</pre>
                 symbolStack.pop();
                 statusStack.pop();
              }
              symbolStack.push(production.head()); // 将左部压入符号栈
              statusStack.push(statusStack.peek().getGoto(production.head())); // 将 GOTO
表查询结果压入状态栈
              break;
          case Shift: // sx
              symbolStack.push(symbol.getKind()); // 将输入队列头压入符号栈
              buffer.remove(∅);
              statusStack.push(action.getStatus()); // 将 LR 表查询结果压入状态栈
              break;
          case Accept: // 语法分析成功
              System.out.println("Parser exits successfully!");
              return ;
          case Error: // 语法分析失败
              System.out.println("Parser exits with errors!");
              return;
          default:
              System.out.println("Unknown action kind.");
              return ;
      }
   }
```

# 3.3 语义分析和中间代码生成

### 3.3.1 翻译方案

仅实现了符号表的更新完善,和对赋值语句、算术运算的中间代码生成,故采取了 PPT 中介绍的通过分析栈进行语义分析的方法。

### 语义分析栈执行动作说明:

- 1、语义分析的结果是更新符号表,根据翻译方案,语义 分析栈需要保存type属性;
- 2、自底向上的分析过程中Shift时将符号的type属性(从 Token中获得)入栈:
- 3、当D->int这条产生式归约时,int这个token应该在语义分析栈中,把这个token的type类型赋值给D的type;
- 4、当S->D id这条产生式归约时,取出D的type,这个type就是id的type,更新符号表中相应变量的type信息,压入空记录占位(D id被归约为S, S不需要携带信息);

## 3.3.2 语义分析和中间代码生成的数据结构

使用了单独的 type 栈和 IRValue 栈:

private Stack<IRValue> irStack = new Stack<>();
private Stack<String> attributeStack = new Stack<>();
还有一个用于暂时存储中间代码的列表结构:
private List<Instruction> irs = new ArrayList<>();

#### 3.3.3 语法分析程序设计思路和算法描述

设计思路:通过栈进行语义分析。

算法描述:由于我们使用基于自底向上语法分析+S-SDD的语法制导翻译方案,故而只需在`whenShift`时将属性进栈,在归约(也即`whenReduce`)时根据产生式的类型进行符号表的更新 or 中间代码的生成。

在实验具体设计中,将符号表更新和中间代码生成拆开来实现,更具解耦性。

#### 1. 中间代码生成

由于我们只需关注对赋值语句和算术运算语句的实现,故而只需关注这几条语句的归约:

ſ	6	S -> id = E;
I	7	S -> return E;
S	8	E -> E + A;
	9	E -> E - A;
t	10	E -> A;
t	11	A -> A * B;
-		

#### (1) case 6

此时是对赋值语句进行归约,需生成一个 MOV 中间代码,E 和 id 分别位于 stack[top]和 stack[top-1]的位置:

```
IRValue irv = irStack.peek();
irStack.pop();
irs.add(Instruction.createMov(((IRVariable)irStack.peek()), irv));
irStack.pop();
break;
```

#### (2) case 7

此时是对返回语句进行归约,需生成一个 Ret 中间代码, E 位于 stack[top]的位置:

```
irs.add(Instruction.createRet(irStack.peek()));
irStack.pop();
```

#### (3) case 8

此时是对算术运算中的加法语句进行归约,需生成一个 ADD 中间代码,A 和 E 分别位于 stack[top]和 stack[top-1]的位置,并且将归约结果入栈。注意,此时需要产生一个临时变量用于存储 A 和 E 的运算结果,并且需要再次将临时变量入栈:

```
IRValue lhs = irStack.peek();
irStack.pop();
IRValue rhs = irStack.peek();
irStack.pop();
IRVariable t = IRVariable.temp();
irs.add(Instruction.createAdd(t, rhs, lhs));
irStack.push(t);
break;
```

### (4) case 9

此时是对算术运算中的减法语句进行归约,需生成一个 SUB 中间代码,A 和 E 分别位于 stack[top]和 stack[top-1]的位置,并且将归约结果入栈。注意,此时需要产生一个临时变量用于存储 A 和 E 的运算结果,并且需要再次将临时变量入栈:

```
IRValue lhs = irStack.peek();
```

```
irStack.pop();
IRValue rhs = irStack.peek();
irStack.pop();
IRVariable t = IRVariable.temp();
irs.add(Instruction.createSub(t, rhs, lhs));
irStack.push(t);
break;
```

#### (5) case 11

此时是对算术运算中的乘法语句进行归约,需生成一个 MUL 中间代码,A 和 E 分别位于 stack[top]和 stack[top-1]的位置,并且将归约结果入栈。注意,此时需要产生一个临时变量用于存储 A 和 E 的运算结果,并且需要再次将临时变量入栈:

```
IRValue lhs = irStack.peek();
irStack.pop();
IRValue rhs = irStack.peek();
irStack.pop();
IRVariable t = IRVariable.temp();
irs.add(Instruction.createMul(t, rhs, lhs));
irStack.push(t);
break;
```

## 2. 符号表更新

只需关注这几条语句的归约:

#### (1) case 4

此时是对声明语句进行归约,需将符号表中 id 的类型更新为 D, 简化实现起见默认为 INT 类型, 并且出栈:

```
if (symbolTable.has(attributeStack.peek())) {
    symbolTable.get(attributeStack.peek()).setType(SourceCodeType.Int);
}
attributeStack.pop();
```

#### (2) case 5

此时是对类型进行归约,简化实现起见默认为 INT 类型,所以直接出栈:

```
attributeStack.pop();
```

## 3.4 目标代码生成

### 3.4.1 设计思路和算法描述

设计思路:将上述实验的结果整合出来的中间代码转化为 riscv 代码。仅实现了不完备的寄存器选择。

算法描述:

1. 预处理

在转化中间代码之前,我进行了两个预处理操作:

(1) 调整指令中对操作寄存器的操作次序

根据 riscv 指令集的语法规则,对中间代码进行调整。调整目标:

指令	指令标准格式
MOV	MOV reg1, reg2/imm
ADD	ADD reg1, reg2/imm
SUB	ADD reg1, reg2/imm
MUL	MUL reg1, reg2
RET	RET reg1/imm

其中 MOV 和 RET 指令无需特别处理,因而我们重点在对 ADD、SUB 以及 MUL 指令的处理。

首先,如果两个操作数都是立即数,那我们就直接计算出计算结果,并将该指令转化为一个 MOV 指令:

除了上面这个情况外的其他情况,我们需要针对这三个指令进行不同的处理:

#### (1) ADD

若第一个操作数(lhs)为立即数,我们只需调换两个操作数位置即可:

```
else if (itr.getLHS().isImmediate() || itr.getRHS().isImmediate()) {
    IRValue var = itr.getLHS().isImmediate() ? itr.getRHS() : itr.getLHS();
    IRValue imm = itr.getLHS().isImmediate() ? itr.getLHS() : itr.getRHS();
    itrs.add(Instruction.createAdd(itr.getResult(), var, imm));
}
```

#### (2) **SUB**

若第一个操作数(lhs)为立即数,我们需要新增一个临时变量,用于存放该立即数,将 SUB 指令转化为对两个寄存器的操作:

```
else if (itr.getLHS().isImmediate()) {
    // change to a two-register calculation
    IRVariable t = IRVariable.temp();
    itrs.add(Instruction.createMov(t, itr.getLHS()));
```

```
itrs.add(Instruction.createSub(itr.getResult(), t, itr.getRHS()));
}
```

## (3) MUL

riscv 不提供含立即数的 mul 指令,故而如果两个操作数中如果有立即数,就都需要通过增加 MOV 指令和临时变量的方法将 MUL 指令转化为三寄存器运算:

```
else if (itr.getLHS().isImmediate() || itr.getRHS().isImmediate()) {
    // change to a three-register calculation
    if (itr.getLHS().isImmediate()) {
        IRVariable t = IRVariable.temp();
        itrs.add(Instruction.createMov(t, itr.getLHS()));
        itrs.add(Instruction.createMul(itr.getResult(), t, itr.getRHS()));
    } else {
        IRVariable t = IRVariable.temp();
        itrs.add(Instruction.createMov(t, itr.getRHS()));
        itrs.add(Instruction.createMul(itr.getResult(), itr.getLHS(), t));
    }
}
```

(2) 记录变量的使用信息,以供之后转化使用

在处理完中间代码后,就需要记录所有变量的 refcnt 等信息,以供之后寄存器选择淘汰算法利用。

为了方便查询修改,我设计了如下数据结构:

```
class RegisterInfo {
    public int getRegisterNo();
    public void setRegisterNo(int registerNo);

    public void IncreaseRefcnt();
    public void DecreaseRefcnt();
    public int getRefcnt();
};

Map<IRVariable, RegisterInfo> variables = new HashMap<>();
Map<Integer, Boolean> registers = new HashMap<>();
```

`RegisterInfo`用于代表某一变量的寄存器信息,包括其目前占用的寄存器,以及其 refcnt 两个信息。通过一个 Map<IRVariable, RegisterInfo>来组织该信息。

同时,为了在寄存器选择算法中方便获取空闲寄存器,我设计了 Map<Integer, Boolean> registers 来记录寄存器的信息。

在编写代码中,需要保证这两个字段的一致性。

在预处理过程中,我们需要遍历所有预处理完之后的指令,记录指令中涉及到变量的引用信息(在此仅以指令中 result 位变量的记录为例):

```
if (variables.containsKey(itr.getResult())) {
    variables.get(itr.getResult()).IncreaseRefcnt();
} else {
    variables.put(itr.getResult(), new RegisterInfo());
}
```

#### 2. 寄存器选择

由于为非完备寄存器选择,故而实现思路较为简单。我们提供一两个对外接口,proccessInvalid 和 getRegister。

### 1 proccessInvalid

在每次转化完一条指令都对其进行调用,用于集中处理那些引用次数为 0 的变量,释放其寄存器。

#### 2 getRegister

首先试图返回该变量已经占用的寄存器; 若没有, 寻找一个空闲寄存器并占用。

```
private int getRegister(IRValue result) {
   int registerNo = variables.get(result).getRegisterNo();
    if (registerNo != Integer.MAX_VALUE) {
       variables.get(result).DecreaseRefcnt();
       return registerNo;
    }
   // a steal
    for (Map.Entry<Integer, Boolean> en : registers.entrySet()) {
       if (en.getValue()) continue; // is occupied
       registerNo = en.getKey();
       variables.get(result).setRegisterNo(en.getKey());
       break;
   }
   if (registerNo == Integer.MAX_VALUE)
       throw new RuntimeException();
    registers.put(registerNo, true);
    variables.get(result).DecreaseRefcnt();
    return registerNo;
```

## 3. 代码生成

经过预处理之后,中间代码的语义已经十分明确。生成过程需要做的就是根据指令的类型进行简单的字符串操作、调用上面两个寄存器选择函数即可,不做赘述。

# 4 实验结果与分析

对实验的输入输出结果进行展示与分析。注意:要求给出编译器各阶段(词法分析、语法分析、中间代码生成、目标代码生成)的输入输出并进行分析说明。

# 4.1 词法分析

```
输入: 'input_code.txt'
int result;
int a;
int b;
int c;
a = 8;
b = 5;
c = 3 - a;
result = a * b - ( 3 + b ) * ( c - a );
return result;
输出:符号表和 token list。形式化打印后如下。
token list:
(int,)
(id,result)
(Semicolon,)
(int,)
(id,a)
(Semicolon,)
(int,)
(id,b)
(Semicolon,)
(int,)
(id,c)
(Semicolon,)
(id,a)
(=,)
(IntConst,8)
(Semicolon,)
(id,b)
(=,)
(IntConst,5)
(Semicolon,)
(id,c)
```

```
(=,)
(IntConst,3)
(-,)
(id,a)
(Semicolon,)
(id,result)
(=,)
(id,a)
(*,)
(id,b)
(-,)
((,)
(IntConst,3)
(+,)
(id,b)
(),)
(*,)
((,)
(id,c)
(-,)
(id,a)
(),)
(Semicolon,)
(return,)
(id,result)
(Semicolon,)
($,)
          (还没进行语义分析,所以类型字段为 null)
符号表:
(a, null)
(b, null)
(c, null)
(result, null)
4.2 语法分析
输入: `input_code.txt`【PPT 示例】
int a;
```

```
输出:语法分析过程使用的产生式列表,以及语法分析成功的控制台输出。形式化打印后如下。
D-> int
```

int c; c = 3-a;

 $S \rightarrow D id$ 

```
D -> int
S -> D id
B -> IntConst
A -> B
E -> A
B -> id
A -> B
E -> E -- A
S -> id = E
S_list -> S Semicolon
S_list -> S Semicolon S_list
S_list -> S Semicolon S_list
P -> S_list

Main ×

T "C:\Program Files\Java\jdk-17\
```

# 4.3 语义分析

输入:语义分析通过观察者模式,绑定在了语法分析的实现过程中,故而输入与语法分析相近,外加一个符号表。

输出: 更新后的符号表和生成的中间代码,还有通过 IREmulator 的代码执行结果。

符号表: (经过语义分析,已经填充了类型字段)

Parser exits successfully!

```
(a, Int)
(b, Int)
(c, Int)
(result, Int)
中间代码:
(MOV, a, 8)
(MOV, b, 5)
(SUB, \$0, 3, a)
(MOV, c, \$0)
(MUL, \$1, a, b)
(ADD, \$2, 3, b)
(SUB, $3, c, a)
(MUL, $4, $2, $3)
(SUB, $5, $1, $4)
(MOV, result, $5)
(RET, , result)
```

中间代码执行结果:

144

# 4.4 目标代码生成

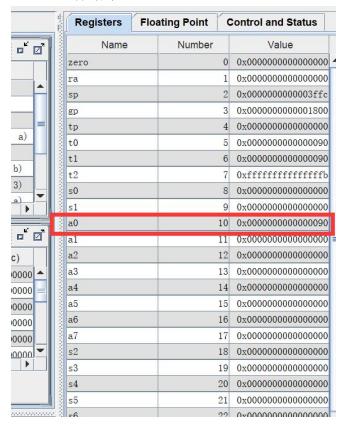
输入:中间代码

输出: riscv 代码,以及 RARS 的运行结果

riscv 代码:

```
.text
    li t0, 8
                 # (MOV, a, 8)
    li t1, 5
                 # (MOV, b, 5)
    li t2, 3
                 # (MOV, $6, 3)
    sub t3, t2, t0
                      # (SUB, $0, $6, a)
    mv t2, t3
                      # (MOV, c, $0)
    mul t3, t0, t1
                      # (MUL, $1, a, b)
                      \# (ADD, $2, b, 3)
    addi t4, t1, 3
    sub t1, t2, t0
                      # (SUB, $3, c, a)
                      # (MUL, $4, $2, $3)
    mul t0, t4, t1
    sub t1, t3, t0
                      # (SUB, $5, $1, $4)
    mv t0, t1
                      # (MOV, result, $5)
    mv a0, t0
                      # (RET, , result)
```

RARS 运行结果:



# 5 实验中遇到的困难与解决办法

描述实验中遇到的困难与解决办法,对实验的意见与建议或收获。

# 5.1 困难与解决办法

整个实验过程没有太难以解决的困难,PPT 和授课都很清楚,不清楚的地方也可以通过学习理论课补充。

每个实验具体耗时如下:

lab1	3h
lab2	2h
lab3	4h
lab4	2h

# 5.2 收获与建议

实验设计很好很现代,让我亲自动手从零开始实现了一个简易的编译器,与理论课程结合十分紧密,让我掌握了编译器内部实现的大体面貌,也拉起了我对编译原理的学习兴趣。

美中不足的是感觉课时安排有点奇怪,比如实验二内容偏简单,但课时太长了,导致中间很长一段时间没碰编译原理,再做实验三的时候全都忘光了就学了很久()

还有一点小小建议,感觉指导书可以再加点拓展阅读内容,大概介绍一下当前前沿的技术是怎么处理该阶段的,权当一个小科普。